ADR: выполнение pipeline вне HTTP-процесса

Контекст и постановка проблемы

Qwen, проверки и упаковка занимают больше времени, чем обычный HTTP-запрос.

Нужно сохранять прогресс и не терять состояние при остановке API.

Статус

ПРИНЯТО в командном плане 03_Yaroslav_Python_Pipeline.md для P0.

Python worker и SQL RunRepository Романа объединены; PostgreSQL concurrency требует живого прогона.

Альтернативы

| Вариант | Плюсы | Минусы |

| --- | --- | --- |

| BackgroundTasks/память API | Простой старт | Потеря очереди при рестарте; нет нужной durability |

| PostgreSQL runs + worker | Состояние и очередь в одной БД; короткие транзакции | Нужны DB constraints, claim/heartbeat/stale logic |

| Celery/Redis или Kafka | Больше возможностей очередей | Дополнительные компоненты и настройка за пределами P0 |

Принятое решение

API делегирует создание queued run repository и возвращает 202. Worker вызывает

claim_next с commit до LLM, пишет heartbeat, выполняет шаги с immutable files.

После прерывания stale run должен стать failed; новый запуск вместо auto-resume.

Последствия принятого решения

Один worker в P0. Не заявляются exactly-once, параллельные workers или fencing.

Модуль БД и RunRepository остаются у Романа, Qwen у Владимира, runner у Дмитрия.

Compose использует отдельные API/worker процессы с общим generated volume.

Ответственные

Ярослав — composition/lifecycle; Роман — PostgreSQL/repository; Дмитрий — deployment.

Внешний лист согласования и корпоративное одобрение не предоставлены.